

PI-JWM 模型版本进展与实验结果记录

禹尧坤

2026-06-26

记录说明

本文档只记录 PI-JWM 模型版本推进和各版本实验结果。ToN 论文式背景、相关工作、系统建模和正式方法叙述移至 `pi_jwm_ton_draft_zh.tex`；本文件不再承担论文正文功能。早期 v0–v5 的日期按本地历史报告文件记录日期填写，v6 以后按实验目录、报告或交接文件中的日期填写。表中 $\uparrow$ 表示越大越好， $\downarrow$ 表示越小越好；粗体表示该表内该指标最优。AirFogSim/SUMO 只作为参考仿真器和数据来源，主框架始终为 PI-JWM。

1 版本进展总览

本节按版本记录模型、符号和结果。表中 $\uparrow$ 表示越大越好， $\downarrow$ 表示越小越好；粗体表示该表内该指标最优。早期 v0–v5 的结果来自 `airfogsim_v0/reports` 中的历史报告，保留当时报告里的变量名和指标名；v6 以后来自 `代码/artifacts/experiments/pi_jwm_*` 下的 PI-JWM 正式实验。若本节使用了统一符号中后补的写法，会在对应段落说明补充来源。

2 v0：动作条件输入接口与最小 world model (2026-05-17)

v0 首先解决“模型到底看什么、预测什么”的问题。当时报告使用 $\mathbf{s}$ 表示状态序列， $\mathbf{a}$ 表示调度动作序列，形式为

$$(\mathbf{s}_{t-H+1:t}, \mathbf{a}_{t-H+1:t+K-1}) \mapsto \hat{\mathbf{s}}_{t+1:t+K}.$$

这一符号早于后续 G_t^{phy} 、 G_t^{info} 的双图拆分；本文开头的统一符号是在 v6 双图建模之后补充的总括写法，不回填改变 v0 当时的实验口径。方法上，v0 已经把节点历史、链路历史、任务历史和 edge-level actions 接入同一个预测器；这一步和 Ha 与 Schmidhuber 的 world model 思想一致，也为后续 Dreamer-style latent imagination 铺路。

v0 有两类结果留存。第一类是 action-conditioned Ridge baseline，用来验证动作是否真的携带状态转移信息；第二类是第一版 `world_model_v0` 神经网络，用来验证一体化接口能否跑通。结果如下。

模型	all RMSE↓	link-rate RMSE↓	task RMSE↓	来源
state-only Ridge	3.303	6.265	1.209	action-conditioned report
state-action Ridge	2.990	5.824	0.785	action-conditioned report

表 1: v0 动作条件 baseline 在 held-out seed 4 上的结果。

模型	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	task RMSE↓
edge-action Ridge	0.873	—	5.139	—
structured state-action	—	—	8.292	0.646
world_model_v0	0.710	564.480	65.299	6.395

表 2: v0 神经 world model 与专用 baseline 的 test seed 4 对照，来源为 world_model_v0_report.md。

这两个表的含义不同。第一张表说明动作变量有效：加入动作后，overall RMSE、link-rate RMSE 和 task RMSE 都下降。第二张表说明第一版神经 world model 只是接口骨架，activity 可以预测到一定程度，但 active-rate 和 task 明显不如专用 baseline。因此 v0 的论文位置应写成“定义动作条件预测契约”，不能写成性能胜利。

3 v1: 稀疏 activity 的分阶段训练（2026-05-17）

v1 保留 v0 的输入输出契约，但改变训练协议。当时报告仍使用 activity precision/recall/F1、rate_all RMSE、rate_active RMSE 和 task RMSE；本文后续把 rate_active_rmse 统一写作 active-rate RMSE，这是从 v6 指标整理时补充的命名，并未改变数值含义。v1 的主要理论依据是：activity 是极端稀疏二分类问题，Lin 等人的 focal loss 直接对应难样本聚焦；多任务 loss 的尺度冲突可由 Kendall 等人的不确定性加权思想和 GradNorm 解释。

模型	threshold	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	task RMSE↓
world_model_v0	0.97	0.710	564.480	65.299	6.395
world_model_v1_staged	0.63	0.663	565.567	18.507	7.676

表 3: v1 staged training 与 v0 的 test seed 4 对比，来源为 world_model_v1_staged_report.md。

v1 的结果很像一次“训练协议排查”：link-rate RMSE 从 65.299 大幅降到 18.507，但 activity F1、active-rate 和 task 没有同步改善。这说明 staged training 能修复全边 rate 的尺度问题，却没有解决 active edge 上的幅值预测，也没有让任务状态稳定下来。这个结论后面直接影响了 v2：需要显式隐状态和 rollout，而不是继续只调训练阶段。

4 v2: 显式 latent rollout (2026-05-17)

v2 首次引入当时报告中的 edge latent 符号 $z_{e,t}$:

$$z_{e,t} = \text{Enc}(\text{edge history}, \text{src/dst node history}, \text{task history}, \text{edge action history}),$$

$$z_{e,t+k} = \text{GRU}(z_{e,t+k-1}, a_{e,t+k-1}).$$

这里的 $z_{e,t}$ 是 edge-level deterministic latent, 和本文统一符号里的 z_t 是局部到全局的关系: z_t 是后续为了论文叙述补充的总称, v2 当时实际实现和报告均以 $z_{e,t}$ 为主。Hafner 等人的 latent imagination 支持把动作条件预测写成递推隐状态, 而不是一次性 direct decoder。

模型	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	task RMSE↓
world_model_v0	0.710	564.480	65.299	6.395
world_model_v1_staged	0.663	565.567	18.507	7.676
world_model_v2_latent_rollout	0.408	570.085	18.638	8.576

表 4: v2 latent rollout 与 v0/v1 的 test seed 4 对比, 来源为 world_model_v2_latent_rollout_report.md。

v2 没有带来指标提升, 但它完成了结构升级: 模型从 direct multi-horizon decoder 变为 action-conditioned latent rollout。这个结果不能删, 因为后续 v3、v4、v8 的 recurrent latent 都是在这个结构线上继续发展。准确说, v2 的失败暴露了“只加隐状态不加图结构”不足以解释链路活动。

5 v3: 通信图消息传递 (2026-05-18)

v3 在 v2 的 $z_{e,t}$ 上加入通信图消息传递。当时报告写作

$$z_t = \text{GraphMessagePassing}(z_t, \text{edge_src_idx}, \text{edge_dst_idx}),$$

$$z_{e,t+k} = \text{GraphMessagePassing}(\text{GRU}(z_{e,t+k-1}, a_{e,t+k-1}, z_{\text{task},t+k-1})).$$

这个符号是实现侧命名, edge_src_idx 和 edge_dst_idx 对应候选 directed communication edges。无线资源管理中的 edge-update GNN 由 ENGNN 给出了直接相关的建模依据。

模型	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	task RMSE↓
world_model_v2_latent_rollout	0.408	570.085	18.638	8.576
world_model_v3_graph_rollout	0.926	569.704	18.825	7.006

表 5: v3 communication graph rollout 与 v2 的 test seed 4 对比, 来源为 world_model_v3_graph_rollout_report.md。

v3 的核心发现是: 通信图上下文明显改善 activity, F1 从 0.408 提升到 0.926; 但 active-rate RMSE 只从 570.085 到 569.704, 几乎没有实质下降。这是后续所有 active-rate 专项工作的起点: 判断“是否活跃”和预测“活跃后的速率幅值”不是同一个难度层级。

6 v4: 物理边特征与双图雏形 (2026-05-28)

v4 引入物理边分支，保留当时报告中的两个 latent 名称：

$$z_{comm} = \text{Enc}_{comm}(\text{link history}, x_{src}, x_{dst}, q, a), \quad z_{phy} = \text{Enc}_{phy}(\text{physical edge}, x_{src}, x_{dst}, q).$$

融合形式写作

$$z_{e,t} = \text{Fuse}(\text{GraphComm}(z_{comm}), \text{GraphPhy}(z_{phy})).$$

后续 v6 的 G_t^{phy} 、 G_t^{info} 是在 v4 的 z_{phy}/z_{comm} 基础上补充的论文级图符号。物理图与信息图分离后，自然对应异构关系建模；HAN 和 HGT 给了后续按关系类型融合的依据。

模型	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	task RMSE↓
world_model_v3_graph_rollout	0.926	569.704	18.825	7.006
world_model_v4_dual_graph_rollout	0.973	569.544	18.634	5.460

表 6: v4 dual-graph rollout 与 v3 的 test seed 4 主结果，来源为 world_model_v4_dual_graph_rollout_report.md。

主结果显示 v4 在 activity、link-rate 和 task 上都优于 v3，但 v4 后续追加了消融和 seed stability，结论必须更谨慎。消融结果如下。

physical variant	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	task RMSE↓
dual_full	0.280	571.008	18.960	5.056
no_physical	0.957	572.783	18.824	4.618
distance_only	0.914	568.200	18.590	5.314
distance_height_speed	0.817	572.626	19.014	6.666

表 7: v4 physical branch 消融结果，来源为 world_model_v4_dual_graph_ablation_report.md。

physical variant	runs	activity F1 mean↑	activity F1 std↓	active-rate RMSE mean↓	task RMSE mean↓
dual_full	3	0.627	0.326	571.078	5.746
no_physical	3	0.884	0.068	572.600	6.464

表 8: v4 seed stability 摘要，来源为 world_model_v4_seed_stability_report.md。

因此 v4 的严谨结论是：物理信息有早期正向信号，尤其 distance-only 对 active-rate/link-rate 有帮助；但 full physical branch 对初始化和阈值敏感，不能把单次 dual-full 结果直接作为最终主方法。这个结论后来推动了 v6 的 same-split dual/physical-only/information-only 正式消融。

7 v5: 决策接口诊断 (2026-05-29)

v5 没有继续作为主模型推进，而是作为 decision/ranking 诊断接口。当时符号从状态预测切到候选动作集合 $\mathcal{A}(s_t)$ 、utility $U(a; s_t)$ 、top-1 hit、normalized regret 和 Spearman。这个分支的理论位置接近 model predictive control: Camacho 和 Bordons 的 MPC 强调用模型评估候选动作后果；但在 PI-JWM 主线中，v5 只回答“预测模型以后怎么接决策”，不替代状态 rollout 任务。

stage	best model	top-1↑	regret↓	Spearman↑
compute	predict_default	1.000	0.000	1.000
offload_rb	predict_low_rb_mixed_bonus	0.400	0.033	0.806
return_route	predict_minus_total_rb	1.000	0.000	0.988

表 9: v5 stage diagnostics 的 test split 最优读数，来源为 world_model_v5_stage_diagnostics_v0_report.md。

数据集	方法	top-1↑	regret↓	Spearman↑
v3	learned_gap1_w0.3_reg0.2	0.691	0.063	0.641
v3	predict_total_rb_baseline	0.604	0.093	0.627
v4	hybrid_max_total_rb_train_selected_margin	0.633	0.126	0.216
v4	predict_total_rb_baseline	0.550	0.150	0.601

表 10: v5 v3-to-v4 scale-up 摘要，来源为 v3_v4_scaleup_summary_report.md。

v5 的结果说明 offload/RB 是决策侧最难阶段，compute 和 return-route 更多是候选集合较小或规则较强的问题。这一节要保留，但在汇报中应弱化为“诊断接口”，因为当前主线仍是先把状态 rollout 做好。

8 v6: 物理-信息双图 rollout baseline (2026-06-09)

v6 把 v4 的 z_{phy}/z_{comm} 正式整理为物理图 G_t^{phy} 与信息图 G_t^{info} 。当时 full80 结果使用 seed0-9 PI-JWM dataset, train=1520、val=190、test=190，三种模式分别是 dual、physical-only 和 information-only。输出仍为 node、activity、link-rate 和 task 四头，rate 指标从 v6 开始明确拆成 all-link link-rate RMSE 与 active-rate RMSE。

模式	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	node RMSE↓	task RMSE↓
dual	1.000	228.318	6.416	38.283	3.664
physical-only	1.000	268.036	7.474	37.067	4.856
information-only	1.000	235.526	6.563	37.305	3.381
flat MLP baseline	0.054	444.208	27.822	112.592	10.780
active-only Ridge diagnostic	–	95.931	–	–	–

表 11: v6 full80 正式消融结果，来源为 pi_jwm_609_metrics.csv。

v6 是第一个可以正面支撑双图主线的版本。dual 在 active-rate 和 link-rate 上同时优于 physical-only 与 information-only，说明物理几何和信息状态在链路速率上互补；但 task RMSE 由 information-only 最好，node RMSE 由 physical-only 最好，说明不同预测头偏好的图信息不同。这个发现直接引出 v7：融合不应只是 concat，而应让不同关系在不同目标上自适应交互。

9 v7: 跨注意力融合与 active-rate 专项优化（2026-06-14）

v7 先处理融合方式。保留当时实现符号，物理、信息、动作三路表示被看作 token，跨注意力写为

$$h_t^{phy \leftarrow info} = \text{Attn}(W_Q h_t^{phy}, W_K h_t^{info}, W_V h_t^{info}),$$

$$h_t^{info \leftarrow phy} = \text{Attn}(W_Q h_t^{info}, W_K h_t^{phy}, W_V h_t^{phy}).$$

Vaswani 等人的 scaled dot-product attention 给出基础算子，Tsai 等人的 Multimodal Transformer 支持把跨模态交互用于不同来源表示融合。

融合方式	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	node RMSE↓	task RMSE↓
concat	1.000	228.318	6.416	38.283	3.664
gated	0.982	233.775	6.640	38.630	3.443
cross-attention	0.975	226.394	6.469	40.683	3.226

表 12: v7 fusion full80 对比，来源为 pi_jwm_v7_fusion_full80_metrics.csv。

fusion 表显示 cross-attention 对 active-rate 和 task 有正向信号，但 activity 和 link-rate 并非全赢。因此 v7 后半段改为 active-rate 专项优化，保留同一 seed-heldout split，并新增 active-mixed loss、activity-gated rate head、residual-gated head 和 active-selected auxiliary output。

方法	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	task RMSE↓
v6 dual baseline	1.000	228.318	6.416	3.664
v7 cross-attention + active-mixed	0.962	209.778	7.287	3.688
v7 activity-gated	0.898	211.713	6.338	5.044
v7 residual-gated	0.929	216.222	6.816	3.721
v7.6 aux-soft-zero, $w = 0.3$	0.908	206.641	6.809	4.305

表 13: v7 rate 侧主要实验结果，来源为 active_rate_auxiliary_comparison.md 与 active_selected_comparison.md。

active-rate specialist	val RMSE↓	test RMSE↓	test MAE↓
random forest	73.318	92.862	57.253
hist GBR	86.194	93.449	64.296
ridge	72.224	97.136	65.325
train active mean	274.100	292.711	264.247
zero rate	558.677	491.313	403.487

表 14: v7 active-rate specialist headroom，来源为 v7_active_rate_specialist_report.md。

v7 的细致结论是：end-to-end neural PI-JWM 可以把 active-rate RMSE 从 228.318 降到 206.641，但代价是 activity F1 和 task 退化；random forest specialist 的 92.862 是 headroom，不是主模型结果。也就是说，数据中确实有可学的 active-rate 幅值信号，但当前神经 rollout 还没有充分吸收。

10 v8：模块级结构消融（2026-06-15）

v8 不再直接叠加所有模块，而是做 same-split GPU 消融。符号上，STGCN-style history encoder 保留时空图卷积写法：

$$H^{(1)} = \Gamma_1 *_{\mathcal{T}} X, \quad H^{(2)} = \sigma \left(\sum_{k=0}^{K_g} \Theta_k A^k H^{(1)} \right), \quad H^{out} = \Gamma_2 *_{\mathcal{T}} H^{(2)}.$$

Yu 等人的 STGCN 给出时间卷积-图卷积-时间卷积的基本结构；更广义的时空图预测综述和图神经网络时间序列综述支持把 history encoder 单独作为模块消融。recurrent latent transition 继续使用 $z_{t+k} = \text{GRU}_{\theta}(z_{t+k-1}, [a_{t+k-1}, c_{t+k-1}])$ ，其动机来自 Dreamer。MoE rate head 写为 $\hat{r}_e = \sum_m \pi_m(h_e) m_m(h_e)$ ，对应 mixture-of-experts 传统综述和近期 MoE 综述。M5 的 loss balancing 则来自多任务学习、uncertainty weighting 和 GradNorm 的共同动机。

实验	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	node RMSE↓	task RMSE↓	判断
v8 gated aux MLP	0.964	230.302	6.462	40.610	4.428	旧基线
v8 base cross aux	0.930	219.564	6.322	50.427	5.190	cross-attention 有效
v8 temporal conv	0.859	208.722	6.592	60.398	2.980	rate 明显改善
v8 recurrent latent	0.846	204.915	9.181	65.953	4.316	rate 最优但副作用大
v8 STGCN-light	0.898	216.956	6.644	69.548	3.474	有改善但不如 temporal/recurrent
v8 STGCN-full	0.862	218.493	6.329	56.498	4.313	标准 STGCN 不占优
v8 MoE	0.935	236.997	6.746	57.537	5.342	不推荐
M5 recurrent balanced	0.964	214.680	6.042	35.489	5.553	稳定性最好

表 15: v8 same-split GPU 模块验证结果，来源为 v8_full_ablation_metrics.md 及 M5 balanced 追加结果。

实验	activity F1↑	active-rate RMSE↓	link-rate RMSE↓	node RMSE↓	task RMSE↓	判断
STGCN-full + recurrent + M5	0.893	218.939	7.345	52.452	2.960	task 最好，但整体不如 M5
STGCN-full + recurrent + MoE + M5	0.898	218.066	9.172	53.991	5.228	MoE 没有互补收益
STGCN-light + recurrent + M5	0.846	243.614	6.850	50.490	3.282	不推荐

表 16: v8 全模块堆叠假设验证结果，来源为 pi_jwm_v8_gpu_combined_stack_20260615。

v8 的结论很硬：recurrent latent 的 active-rate 最好，但带来 activity、link-rate 和 node 退化；M5 balanced 是当前整体最稳候选；STGCN 和 MoE 都有论文依据，也确实接入并训练过，但当前数据上不能作为默认主模型。全模块堆叠没有产生互补收益，所以不能为了“看起来复杂”把它们全部塞进最终方法。

11 v9: active-heavy 数据集、C6 修复与 hurdle refinement (2026-06-16–2026-06-17)

active-heavy v1 是后续扩展数据集，使用 train seeds 0–15、val 16–17、test 18–19。这里的 C6/C7/C8 是 active-heavy 上的候选编号，不等于前面的 v6/v7/v8 主线版本。C6 先做 loss repair: negative sampling 增加少数 active 样本权重，focal loss 进一步抑制易分类 inactive 样本。

实验	activity F1↑	recall↑	active-rate RMSE↓	link-rate RMSE↓	task RMSE↓	判断
C6 baseline M5	0.014	0.024	303.367	84.135	2.690	active 边太稀疏
C6 neg-sample BCE	0.022	0.106	308.543	98.900	2.254	recall 提升有限
C6 neg-sample focal	0.020	0.720	294.011	94.931	2.791	rate 改善但 false positive 多
candidate pruning hn80	0.017	–	294.351	102.654	–	没有超过 focal baseline

表 17: active-heavy v1 与 C6 loss repair 结果，来源为 c6_loss_repair_comparison.md 和 candidate-pruning 追加结果。

候选 v9 采用 hurdle/event 形式，把“是否活跃”和“活跃后的速率幅值”拆开。Mullahy 的 hurdle model 本来用于零膨胀计数问题，这里借用其事件–幅值分离思想：

$$p_{e,t+k} = P(y_{e,t+k}^{act} = 1 \mid z_{t+k}, e), \quad \hat{r}_{e,t+k} = \mathbf{1}[p_{e,t+k} > \tau] \cdot m_{\theta}(z_{t+k}, e).$$

其中 event memory 是后续为了改善 activity precision/F1 补充的实现模块，不改变 hurdle 的基本两阶段符号。

实验	precision $\uparrow$	recall $\uparrow$	F1 $\uparrow$	active-rate RMSE $\downarrow$	link-rate RMSE $\downarrow$	task RMSE $\downarrow$
C6 focal anchor	0.010	0.720	0.020	294.011	94.931	2.791
C7 precision checkpoint	0.013	0.408	0.025	299.318	96.949	3.038
C8a hurdle only	0.020	0.043	0.027	292.830	89.142	3.420
C8b event memory only	0.055	0.104	0.072	300.189	102.459	2.594
C8c hurdle + event	0.013	0.350	0.025	306.289	98.659	2.745

表 18: 候选 v9 hurdle/event 消融结果，来源为 v9_candidate_comparison.md。

第一轮候选说明 hurdle/event 方向成立，但不同目标仍然分裂：C8a 是 active-rate/link-rate 方向最好，C8b 是 precision/F1 方向最好。远端随后补跑了 v9 hurdle refinement，固定 model_rate_output_mode=hurdle_soft，在 precision-constrained composite checkpoint 下调节 τ 约束、negative sampling ratio、rate loss weight 和训练轮数。这里的 τ 是 activity gate 的输出阈值，不改变 hurdle model 的两阶段定义；Aux RMSE 是 auxiliary active-rate head 的读数，不等于最终 main output。

实验	P $\uparrow$	R $\uparrow$	F1 $\uparrow$	active-rate RMSE $\downarrow$	Aux RMSE $\downarrow$	link RMSE $\downarrow$	node RMSE $\downarrow$	task RMSE $\downarrow$
C6 focal anchor	0.010	0.720	0.020	294.011	290.686	94.931	21.047	2.791
C8a hurdle prev	0.020	0.043	0.027	292.830	293.398	89.142	20.204	3.420
C8b event memory prev	0.055	0.104	0.072	300.189	299.354	102.459	23.753	2.594
r0 hurdle repeat	0.011	0.043	0.018	291.478	291.586	90.425	21.286	3.180
r1 precision relaxed	0.008	0.010	0.009	296.499	295.706	91.390	20.190	3.514
r2 recall relaxed	0.011	0.012	0.012	299.969	301.039	92.806	21.685	2.700
r3 precision tight	0.012	0.022	0.015	303.941	304.217	96.392	19.001	2.401
r4 less neg sampling	0.012	0.034	0.018	292.288	293.498	99.234	20.032	3.483
r5 rate weight high	0.008	0.031	0.012	298.663	298.364	96.359	23.865	2.739
r6 long180	0.020	0.039	0.026	292.681	292.467	94.640	20.763	3.291

表 19: v9 hurdle refinement 远端正式结果，来源为 v9_hurdle_refine_comparison.md；C8b event memory prev 来自 v9_candidate_comparison.md，作为 activity-side 对照保留。

v9 refinement 的结论比第一轮更明确：r0 将 active-rate RMSE 从 C6 anchor 的 294.011 降到 291.478，是当前 active-heavy 数据上的 rate-best；但 r0 的 F1 只有 0.018，低于 C6 anchor 的 0.020，也低于 C8a 的 0.027。按本轮 refine summary，C8a 仍是 balanced night pick，因为它同时保持了较低 active-rate RMSE 292.830 和最佳 link-rate RMSE 89.142；若把上一轮 C8b event memory 一并保留作对照，C8b 仍是 precision/F1 最强信号，但 active-rate 退化到 300.189。因此可以把 v9 写成“hurdle-soft 已经形成 rate-side 改善，event-memory 保留 activity-side 改善”，但还不能宣称二者已经统一成最终主模型。

12 v10–v11 candidate: action-aligned、policy bridge 与策略器候选（2026-06-19–2026-06-22）

2026-06-19 之后的实验将主线从 active-heavy v1 的 world-model 消融推进到 action-aligned v2 数据、frozen rollout evaluator 和 autonomous 策略器评估。该阶段的重要变化不是简单继续调 loss，而是修复 future action condition: v1 中 `edge_a_future` 的动作条件信息不足，而 v2 60-seed 数据使 future action 覆盖真实 active link-step。由此，PI-JWM world model 在 true-future/oracle-style 动作输入下进入约 100 的 active-rate RMSE 区间。

方法	active-rate RMSE↓	link RMSE↓	activity F1↑	active count	结论
v1 C8a anchor	292.830303	89.141847	0.027108	–	v1 动作条件不足
v2 train0–15 control	216.722641	6.928752	0.864652	–	action 对齐后明显改善
v2 hurdle baseline / oracle-style	100.140207	5.377113	0.902439	–	作为 frozen world model 主参考
v2 hurdle repro seed20260619	108.097297	3.941001	0.914439	–	复现实验证明同一强区间
zero future actions	502.550213	12.440349	0.014320	–	future action 是关键输入

表 20: action-aligned v2 数据与 future action 条件诊断，来源为 `pi_jwm_v9_expanded_v2_gpu_20260619/experiment_summary.md`。

v10 在此基础上训练 behavior-cloning scheduler，并建立 policy bridge：策略器根据历史状态生成未来 offload、RB、CPU、return 等动作，再输入 frozen PI-JWM world model 做 rollout。v10 的作用是建立 autonomous baseline，并通过半 oracle 诊断确认后续瓶颈主要在动作值幅值，而不是 activity/ranking。

方法	active-rate RMSE↓	link RMSE↓	activity F1↑	结论
true-future / oracle-style actions	100.140209	5.377113	0.902439	world model 上界较强
raw threshold policy bridge	280.321712	107.205085	0.026096	直接策略输出效果较差
train median + scale 1.32	218.280321	81.549604	0.017657	value 后处理显著改善
codebook k9, threshold 0.4, scale 1.0	217.237962	81.257763	0.023506	v10 autonomous 最好基线
policy activity + true value	122.205507	5.564188	0.884298	activity 路径基本可用
true activity + policy value	314.673188	49.902519	0.232181	value/magnitude 是主瓶颈

表 21: v10 policy bridge 与半 oracle 诊断，来源为 `pi_jwm_v10_policy_bridge*_gpu_20260620`。

v11 仍作为 candidate 处理，不能提前固化为最终版本。已有实验显示，继续用六个独立 value-bin 分类会出现 majority-bin collapse; inverse-sqrt class-balanced CE 能改善 plain CE, 但仍远差于 v10 autonomous baseline。后续又测试了 value calibrator、coupled token、rb_total counterfactual attribution 和 ranked allocation 等方向。counterfactual attribution 说明，只把预测活跃位置上的 `rb_total` 替换成真值，就能在 validation 上达到 119.516783、test 上达到 103.577001，几乎接近 all-values 替换；这把瓶颈从“广义策略器”进一步收窄到 `rb_total` value/magnitude。ranked allocation 在一次 GPU gate confirmation 中取得 matched-test active-rate RMSE 213.160874，但 full-val/test freeze 扩大确认回到 220.225805，说明该方向有信号但稳定性仍不足。

方法	active-rate RMSE↓	link RMSE↓	activity F1↑	active count	结论
v10 autonomous baseline	217.237962	81.257763	0.023506	396	对照基线
independent value-bin CE	303.688435	105.001686	0.028065	–	独立分类失败
inverse-sqrt value-bin CE	277.662153	90.341729	0.030658	–	有改善但仍远差于 v10
value calibrator CPU candidate	214.147383	82.119558	0.028660	396	test 优于 v10, 但以 CPU 诊断为主
value calibrator GPU candidate	217.392624	79.857563	0.028672	396	GPU 确认未优于 v10 active-rate
ranked allocation GPU gate	213.160874	88.984688	0.028302*	396	当前较好 v11 candidate 信号
ranked allocation full-val/test freeze	220.225805	92.823384	0.028661*	396	扩大确认后未稳定优于 v10

表 22: v11 candidate 策略器方向阶段结果。带 * 的 F1 来自后续 CPU frozen-candidate rerun backfill; 对应原始 GPU summary 未保存 per-sample activity 指标, 因此 RMSE 以原始 GPU 结果为准, F1 仅作同配置补记。

v11 后续的代码审计和广义文献调研进一步确认: 继续对当前 action-summary 特征做 CE/focal/pairwise/listwise 小修补, 收益有限。当前 deployable rank/value 相关性偏弱, GPU gate 中 validation score Pearson/Spearman 仅为 0.0205/0.0461, test 为 0.0794/0.0814; train8192 冻结扩展后 matched-test 反而从 213.160874 退到 220.225805。因此不能把“训练样本更多”或“GPU 更大”当成必然改进。下一步应继续留在策略器阶段, 但方法要从宽泛 policy training 改为更直接的 benefit/risk 建模: 把修复某个 edge-step 的 `rb_total` 看成一个候选处理动作, 估计它对 downstream active-rate RMSE 的增益, 并用 support-constrained value repair 和 selective/conformal gate 控制错误修复风险。这一方向对应 heterogeneous treatment effect/uplift ranking、selective prediction/conformal risk control 和 offline support constraint 文献。

截至 2026-06-22 的实际推进原则固定为: v11 仍是 candidate; 当前最好可展示信号是 ranked allocation GPU gate 的 213.160874, 但主结论必须同时说明 full-val/test freeze 未稳定保持; 后续 CPU 先验证 cross-fitted uplift/benefit ranking、selective repair gate 和 support-constrained value repair, 只有 validation/test 均稳定优于 v10 autonomous baseline 217.237962 且 link RMSE 不恶化到风险阈值以上, 才进入更大 GPU 训练。

2026-06-29 的后续推进没有把当前方法改名为新版本, 仍归入 v11 candidate 的策略器阶段。由于直接行为克隆、独立 value-bin、support-aware edge loss 和简单 post-hoc calibration 均未稳定超过 v10 autonomous baseline, 本轮改为使用 frozen PI-JWM rollout evaluator 直接评价候选动作模板: 同一个历史状态下生成多组 future action, 再按实际 rollout active-rate RMSE 训练或选择模板。该方向的意义不是替代 world model, 而是把策略器问题改写为 actual-rollout candidate selection。服务器输出已同步到本地, 汇总索引为 代码/artifacts/reports/ppt_v11_candidate_20260629/experiment_evidence_index.md。

实验	候选数	best-val RMSE↓	best-val→test RMSE↓	test oracle RMSE↓	判断
pairwise quota 512	13	220.537045	235.081397	208.788876	val 选择未能泛化到 test
val/test256 seed0	13	221.523374	218.956365	199.281621	小样本接近 v10, 但不能作最终结论
val/test256 seed20260630	13	229.616248	216.897951	201.554773	小样本低于 217.237962
val/test256 seed20260631	13	223.966536	213.041887	203.444126	小样本最好信号, 但 F1 仍低
strict512 seed20260631	13	224.375085	236.977850	210.975399	512 confirmation 失败
rich features strict512	13	230.200314	231.870424	210.975400	rich step features 未改善
train+val fit strict512	13	209.592576	235.618597	210.975402	validation 过拟合, 不能采用
expanded55 strict512	55	226.949165	235.423373	215.394402	候选空间有 headroom, selector 未选准

表 23: v11 candidate actual-rollout template selector 结果。输出目录分别位于 代码/artifacts/experiments/pi_jwm_v11_rollout_reward_template_selector_*; 完整索引见 代码/artifacts/reports/ppt_v11_candidate_20260629/experiment_evidence_index.json。

表中需要特别区分两类结论。第一, val/test256 的三组小规模验证给出了可展示的正向信号: best-val 对应 test 分别为 218.956365、216.897951 和 213.041887, 说明 actual-rollout selector 方向比直接 value-bin 策略器更接近 v10 autonomous baseline。第二, strict512 扩大验证没有通过 stop rule: 13 候选 strict512 的 best-val 对应 test 为 236.977850, expanded55 strict512 的 best-val 对应 test 为 235.423373, 均未稳定优于 217.237962。expanded55 的 test sample-oracle 达到 215.394402、pair-oracle 达到 216.562624, 说明候选空间已经接近 autonomous baseline; 但 deployable selector 最好 test 仍为 227.017662, 瓶颈从“有没有好候选”转为“能否稳定选对候选”。此外, 本轮 activity F1 仍处在约 0.024–0.027 的低区间, 不能只用 active-rate RMSE 宣称整体策略器已经完成。2026-06-29 时据此提出 candidate-level/listwise selector; 下节的 2026-07-13 诊断进一步检查候选监督覆盖, 并据新证据调整优先级。大规模 GPU 训练仍不启动。

13 能耗、逐步收益与 rollout horizon 诊断 (2026-07-13)

前述 v11 candidate 结果说明 selector 的 validation 泛化不稳定, 但该结论仍缺少两个检查: 候选动作是否在任务收益上具有足够区分度, 以及 UAV 能耗是否与任务收益形成可解释的权衡。本轮使用 AirFogSim 作为参考仿真器, 对同一 seed、同一决策时刻的候选动作做配对重放。PI-JWM 仍是研究框架; 本节只补充决策接口的评价协议, 不把仿真器或 action-only ranking head 写成主方法。

对 UAV u 的第 k 个仿真步, 能耗分解为

$$e_{u,k} = c_{fly} I_{u,k}^{fly} + c_{hover} I_{u,k}^{hover} + c_{sense} n_{u,k}^{sense} + c_{rx} b_{u,k}^{rx} + c_{tx} b_{u,k}^{tx},$$

其中 I^{fly} 和 I^{hover} 为飞行/悬停指示量, n^{sense} 为使用中的传感器数量, b^{rx} 和 b^{tx} 为当步收发数据量; c 取自该次 AirFogSim energy 配置。 H 步累计能耗为

$$E_H(c) = \sum_{k=0}^{H-1} \sum_{u \in \mathcal{U}_k} e_{u,k},$$

其单位是仿真器 energy unit, 当前尚未校准为真实焦耳。每一步任务收益定义为

$$u_k(c) = \Delta N_k^{done}(c) - \Delta N_k^{fail}(c) + \eta \log(1 + \Delta B_k(c)), \quad \eta = 0.01,$$

其中 ΔB_k 为 AirFogSim 全局累计通信量 `channel.data_size` 的非负步间增量；不再与 V2I/V2U/U2I 子项重复相加。候选 c 的累计收益、相对默认候选 c_0 的配对效应以及单位步效应分别为

$$U_H(c) = \sum_{k=0}^{H-1} u_k(c), \quad \Delta U_H(c) = U_H(c) - U_H(c_0), \quad \overline{\Delta U}_H(c) = \frac{\Delta U_H(c)}{H}.$$

这里不把能耗直接并入主收益。能耗惩罚只用于敏感性分析：

$$\tilde{U}_{H,\lambda}(c) = U_H(c) - \lambda \frac{E_H(c) - E_H(c_0)}{\max\{|E_H(c_0)|, \epsilon\}},$$

且 λ 不根据 validation/test 事后选择。

候选区分度按决策组计算。设 $\mathcal{G}$ 为固定的 seed–decision-time 组集合， $\mathcal{C}_g$ 为组 g 的候选集合，则

$$\rho_H = \frac{1}{|\mathcal{G}|} \sum_{g \in \mathcal{G}} \mathbb{I} \left[\max_{c \in \mathcal{C}_g} U_H(c) - \min_{c \in \mathcal{C}_g} U_H(c) > 10^{-8} \right].$$

本轮只在决策时刻注入一次候选动作，之后所有候选恢复同一个 default scheduler。因此，增加 H 观察的是单步扰动的延迟后果，不是持续执行另一套多步策略。

H	seeds	step rows	candidates	non-trivial groups $\uparrow$	audit
3	5	198	66	7/15 (46.67%)	pass
10	5	660	66	7/15 (46.67%)	pass
20	5	1320	66	7/15 (46.67%)	pass

表 24: 固定 seeds 0–4、每个 seed 三个决策点下的 horizon 诊断。三行候选集合完全对齐；audit 同时检查 reward 重建、能耗分项守恒、负能耗和动作注入有效性。




图 1: 候选区分度随 rollout horizon 的变化。 $H = 3, 10, 20$ 均只有 7/15 个非平凡决策组，延长观察窗口没有增加有效排序监督。




图 2: 单步动作扰动在不同 horizon 下的单位步 task-utility 配对效应。曲线表示动作族均值，只用于描述暂态效应，不表示跨 horizon 的策略性能排序。

结果给出三个边界明确的判断。第一， ρ_H 在三个 horizon 下均为 46.67%，因此短窗口不是候选监督稀疏的唯一原因。第二，CPU-scale 的 12 个候选和 return-route 的 4 个候选在三个 horizon 下仍无可辨识效应；这不能推出 CPU/return 长期无效，只能说明当前决策点、动作幅度或一次性注入协议没有产生可测差异。第三，offload-target 与 mixed-offload-RB 在 $H = 10$ 的单位步平均效应分别为 -0.014543 和 -0.015761 ，到 $H = 20$ 回到 -0.000129 和 -0.000737 ，表现为中期负效应与后续补偿；该非单调变化不支持“horizon 越长越差”的结论。

能耗配对差异没有随 H 累积，这是实验协议的直接结果：候选只改变第一步动作，后续调度相同。因而本轮能够支持的结论是，当前 actual-rollout candidate library 的有效监督覆盖不足，且部分 offload 效应具有暂态性；它不能证明某个 selector 或某个 λ 已经改善策略。下一步应先构造持续多步候选序列、扩大 compute/return 有效决策点覆盖，再接入 PI-JWM forecast 与不确定性做 rollout-aware selector。完整数据、公式口径、复现命令和 SHA-256 冻结清单位于 代码/artifacts/reports/pi_jwm_energy_reward_horizon_study_20260713/。