

基座模型驱动的网络状态联合预测：阶段性进展梳理

禹尧坤

1 课题说明原文

1.1 课题名称

基座模型驱动的网络状态联合预测。

1.2 一、问题背景

1.2.1 研究场景：网联具身智能体协同的“物理网络-信息网络”联合预测

- 智能体运动导致网络拓扑与资源状态持续演化，缺乏预测则只能被动响应。
- 现有工作大多聚焦单一维度，例如流量预测，忽略物理网络与信息网络协同演化。

1.2.2 研究现状

- ST-GNN 在网络/流量预测中非常成熟，架构多样，例如时空图预测综述 [1] 和 6G 条件时空图预测工作 [2]。
- 通信网络流量时空预测已有专门方法，例如基于 GNN 的通信网络流量预测 [3]。
- 世界模型中 Dreamer 系列 [4] 在 RL 中成熟，但尚未直接用于网络状态预测。
- 动态无线环境下的 GNN 持续学习资源分配 [5] 说明图模型可以处理动态无线网络结构。

1.2.3 关键空白

- “物理网络-信息网络”联合世界模型是全新概念，目前无直接对应工作。
- 基座模型预训练，即“多场景预训练 → 目标场景迁移”，引入网络状态预测，尚未被充分探索。

原文列出的参考方向 ST-GNN 相关工作 [1, 2] 说明图时空预测已有成熟基础；通信网络流量预测工作 [3] 说明信息网络侧可以用图神经网络建模；Dreamer[4] 说明世界模型可通过 latent imagination 支撑控制；动态无线资源分配工作 [5] 说明 GNN 可以表达动态无线环境中的结构关系。

1.3 二、问题描述

1.3.1 问题一：如何构建联合世界模型，捕获智能体与网络资源状态的协同演化？

- 研究物理侧与信息侧的跨域状态表征，形成统一模型输入。
- 研究联合世界模型架构：同时捕获空间依赖和时间演化，建模双向作用关系。
- 设计预测输出：短时细粒度、长时趋势和不确定性估计。

1.3.2 问题二：如何通过基座模型预训练提升跨场景泛化能力？

- 研究在多种协同场景上的预训练策略，获得可迁移的时空表征能力。
- 探索参数高效的微调机制，使新场景少量数据即可适配。
- 验证预训练泛化增益，分析哪些场景多样性对效果影响最大。

1.4 三、后续方向

网联具身智能体协同的“物理网络-信息网络”联合预测。

任务

1. 学习 ST-GNN 和状态空间模型基础，了解世界模型核心思想。
2. 构建具身智能体协同场景数据集，即物理侧和信息侧时序数据。
3. 实现联合世界模型，验证联合预测精度。

预期收获 掌握时空图神经网络与世界模型联合建模，通过预训练提升跨场景泛化能力。

2 老师给出的具体问题

在网络基站覆盖环境下，如何对无人机群的通信资源、计算卸载与运动轨迹进行在线协同决策，使任务时延、能耗同时优化，并在链路波动、任务随机到达和局部观测下保持系统稳定？无人机仍要决定何时本地算、何时卸载到边缘、何时借助同伴中继，以及何时为了后续任务主动靠近“好覆盖区”。利用世界模型对无人机网络状态进行预测，以及对通信网络状态进行预测，有助于资源优化决策。

这段话把课题落到了更具体的无人机场景：预测不是终点，而是为了支撑通信资源、计算卸载和运动轨迹的在线协同决策。

3 当前主线

结合课题原文和老师给出的具体问题，当前主线可以概括为：

先在可控的小规模空地协同场景中跑通仿真数据链路；再将原始日志组织成物理图和通信图的联合时间序列；随后训练双图联合预测模型，并进一步升级为动作条件世界模型；最后通过多场景预训练和目标场景迁移，验证模型是否具备跨场景泛化能力，并支撑通信资源、任务卸载和运动轨迹协同决策。

这条路线与无线网络数字孪生 [6]、生成式 AI 驱动的闭环网络管理 [7]、低空无线网络中感知通信控制协同设计 [8] 等方向一致。相关研究进一步指出，低空无线网络需要系统级控制架构 [9]，因此当前建模不应把物理侧和通信侧割裂处理。

4 总体计划

阶段	核心目标	具体内容
阶段一	课题理解与方向定位	梳理 ST-GNN、世界模型、动态无线资源分配等相关方向，明确当前课题的关键空白是物理网络与信息网络的联合世界模型，以及多场景预训练到目标场景迁移。
阶段二	小场景收缩	将抽象的网联具身智能体协同收缩到“智慧城市空地协同感知”场景，明确无人机、事件点、边缘节点和任务流程。
阶段三	详细建模	定义节点状态、物理边、通信边、双图结构、历史输入窗口、动作变量和未来预测标签，形成可训练样本格式。
阶段四	平台跑通与数据导出	使用 AirFogSim/SUMO 跑通小规模仿真，导出节点、链路、任务和汇总日志，检查这些字段能否支撑双图建模。
阶段五	联合预测 baseline	构造 <code>dataset_v0</code> ，先比较单域预测、直接拼接和双图联合建模，验证联合建模是否带来收益。
阶段六	世界模型 v0	在 baseline 基础上引入隐状态、动作条件状态转移、多步 rollout 和先验/后验约束，使模型从普通预测器走向可推演的世界模型。
阶段七	预训练与迁移	基于不同场景配置生成多场景数据，验证源场景预训练到目标场景微调是否提升泛化能力。
阶段八	决策接口验证	将预测结果接入卸载、资源分配或轨迹调整模块，观察任务时延、能耗、链路稳定性和任务完成率是否改善。

5 详细建模

5.1 场景与实体建模

当前先采用一个小而清楚的场景：智慧城市中的空地协同感知。场景中包含无人机、城市事件点和边缘节点；在 AirFogSim 平台阶段，还可以自然引入车辆、RSU 和云节点作为仿真环境中的扩展实体。任务是城市道路突发事件巡查与数据回传：当道路出现拥堵、事故或人群聚集等事件时，无人机前往事件点采集图像/视频数据，并通过空地链路回传至边缘节点。

首先定义三类核心实体集合：

$$\mathcal{U} = \{u_1, u_2, \dots, u_N\}, \quad \mathcal{S} = \{s_1, s_2, \dots, s_M\}, \quad \mathcal{B} = \{b_1, b_2, \dots, b_R\}. \quad (1)$$

其中， $\mathcal{U}$ 表示无人机集合， $\mathcal{S}$ 表示城市事件点集合， $\mathcal{B}$ 表示边缘节点集合。对于第 m 个事件点，在时刻 t 的任务可定义为：

$$\mathcal{T}_{m,t} = (\mathbf{p}_m, D_{m,t}, C_{m,t}, \tau_{m,t}, \rho_{m,t}). \quad (2)$$

这里， $\mathbf{p}_m$ 表示事件点位置， $D_{m,t}$ 表示待采集或待回传数据量， $C_{m,t}$ 表示计算需求， $\tau_{m,t}$ 表示任务时限， $\rho_{m,t}$ 表示优先级。这样定义的好处是：任务不再只是一个抽象 request，而是能够和无人机运动、通信回传、边缘计算负载发生联系。

5.2 节点状态建模

节点状态只描述实体自身属性，不把距离、速率、时延等关系变量塞进节点里。这样可以避免 $\mathbf{X}$ 和 $\mathbf{E}$ 的语义混乱： $\mathbf{X}$ 表示节点自身状态， $\mathbf{E}$ 表示两个实体之间的关系。

无人机节点 u_i 在时刻 t 的状态定义为：

$$\mathbf{x}_{u_i,t} = [\mathbf{p}_{i,t}, \mathbf{v}_{i,t}, h_{i,t}, b_{i,t}, q_{i,t}, c_{i,t}]. \quad (3)$$

其中， $\mathbf{p}_{i,t}$ 是位置， $\mathbf{v}_{i,t}$ 是速度， $h_{i,t}$ 是高度， $b_{i,t}$ 是剩余能量， $q_{i,t}$ 是本地待回传或待处理队列， $c_{i,t}$ 是本地可用算力。无人机状态体现的是“它现在在哪里、怎么动、还有多少能量和处理能力”。

事件点节点 s_m 在时刻 t 的状态定义为：

$$\mathbf{x}_{s_m,t} = [\mathbf{p}_m, D_{m,t}, C_{m,t}, \tau_{m,t}, \rho_{m,t}]. \quad (4)$$

边缘节点 b_r 在时刻 t 的状态定义为：

$$\mathbf{x}_{b_r,t} = [\mathbf{p}_r, C_{r,t}^{\text{edge}}, B_{r,t}, L_{r,t}]. \quad (5)$$

其中， $\mathbf{p}_r$ 是边缘节点位置， $C_{r,t}^{\text{edge}}$ 是可用边缘算力， $B_{r,t}$ 是可用带宽资源， $L_{r,t}$ 是当前负载。AirFogSim[10] 当前已经能导出车辆、UAV、RSU、云节点的时间序列状态，这些字段可以作为后续节点特征的原始来源。该平台面向 UAV-integrated vehicular fog computing，支持 UAV 轨迹、任务卸载和资源分配等过程模拟。

5.3 物理边建模

物理边描述空间几何关系、感知覆盖关系和相对运动关系。物理边不表示“能不能通信”，而是表示两个实体在物理空间中的关系。例如无人机和事件点之间的物理边表示能否覆盖或感知；无人机和边缘节点之间的物理边表示回传时的空间条件；无人机和无人机之间的物理边表示邻近、协同或碰撞风险。

对于节点 i 和节点 j ，物理边特征可写为：

$$\mathbf{e}_{ij,t}^{\text{phy}} = [d_{ij,t}, \Delta \mathbf{p}_{ij,t}, \Delta h_{ij,t}, \Delta \mathbf{v}_{ij,t}, o_{ij,t}]. \quad (6)$$

其中，

$$d_{ij,t} = \|\mathbf{p}_{i,t} - \mathbf{p}_{j,t}\|_2, \quad \Delta \mathbf{p}_{ij,t} = \mathbf{p}_{i,t} - \mathbf{p}_{j,t}, \quad \Delta \mathbf{v}_{ij,t} = \mathbf{v}_{i,t} - \mathbf{v}_{j,t}. \quad (7)$$

$d_{ij,t}$ 表示空间距离， $\Delta \mathbf{p}_{ij,t}$ 表示相对位置， $\Delta h_{ij,t}$ 表示高度差， $\Delta \mathbf{v}_{ij,t}$ 表示相对速度， $o_{ij,t}$ 表示覆盖或可达指示。以无人机-事件点为例，如果事件点进入无人机感知半径，可以令 $o_{ij,t} = 1$ ；否则令 $o_{ij,t} = 0$ 。

5.4 通信边建模

通信边描述链路连接关系和通信质量。它和物理边有关系，但不是同一个东西。同样是无人机-边缘节点，在物理图中关心距离和高度差，在通信图中关心链路是否可用、速率是多少、时延是多少、资源块分配了多少。

通信边特征可写为：

$$\mathbf{e}_{ij,t}^{\text{comm}} = [c_{ij,t}, r_{ij,t}, \gamma_{ij,t}, \delta_{ij,t}, n_{ij,t}, \eta_{ij,t}]. \quad (8)$$

其中， $c_{ij,t}$ 是连接指示， $r_{ij,t}$ 是传输速率， $\gamma_{ij,t}$ 是 SINR 或 CSI 摘要， $\delta_{ij,t}$ 是传输时延， $n_{ij,t}$ 是噪声或干扰水平， $\eta_{ij,t}$ 是资源占用，例如 RB 分配数。通信网络流量预测 [3] 说明图结构和时间演化需要联合处理，动态无线资源分配工作 [5] 也说明 GNN 适合表达动态无线环境中的结构关系。

在当前 AirFogSim 导出的 `link_states.csv` 中，`distance` 可以对应 $d_{ij,t}$ ，`rate_sum` 可以对应 $r_{ij,t}$ ，`csi_mean` 可以作为 $\gamma_{ij,t}$ 的近似输入，`allocated_rb_count` 可以对应 $\eta_{ij,t}$ 。

5.5 双图联合建模

有了节点状态和边状态后，可以在每个时刻构造两张图。物理图定义为：

$$G_t^{\text{phy}} = (\mathcal{V}^{\text{phy}}, \mathcal{E}_t^{\text{phy}}, \mathbf{X}_t^{\text{phy}}, \mathbf{E}_t^{\text{phy}}). \quad (9)$$

通信图定义为：

$$G_t^{\text{comm}} = (\mathcal{V}^{\text{comm}}, \mathcal{E}_t^{\text{comm}}, \mathbf{X}_t^{\text{comm}}, \mathbf{E}_t^{\text{comm}}). \quad (10)$$

这里 $\mathcal{V}$ 表示节点集合, $\mathcal{E}$ 表示边集合, $\mathbf{X}$ 表示节点特征矩阵, $\mathbf{E}$ 表示边特征集合。两张图可以共享部分节点, 但边的语义不同: 物理图强调空间关系, 通信图强调链路关系。这样做的原因是物理邻近不等于通信可达, 通信可达也不一定代表物理任务可达。

5.6 历史输入窗口与预测标签

模型输入不是单个时刻, 而是过去一段时间窗口。给定历史窗口长度 H , 时刻 t 的输入可以写成:

$$\mathcal{I}_t = \left\{ G_\ell^{\text{phy}}, G_\ell^{\text{comm}}, \mathbf{a}_\ell \right\}_{\ell=t-H+1}^t. \quad (11)$$

其中, $\mathbf{a}_\ell$ 表示动作或调度决策, 包括任务卸载目标、RB/带宽分配、CPU 分配、UAV 移动控制、是否借助同伴中继等。如果第一版 baseline 暂时不接动作, 可以先去掉 $\mathbf{a}_\ell$, 只做无动作条件的状态预测。

未来预测标签定义为:

$$\mathcal{Y}_t = \left\{ \mathbf{Y}_\ell^{\text{node}}, \mathbf{Y}_\ell^{\text{phy-edge}}, \mathbf{Y}_\ell^{\text{comm-edge}}, \mathbf{Y}_\ell^{\text{task}} \right\}_{\ell=t+1}^{t+K}. \quad (12)$$

其中, K 是预测步长。 $\mathbf{Y}^{\text{node}}$ 包含未来节点状态, $\mathbf{Y}^{\text{phy-edge}}$ 包含未来物理边状态, $\mathbf{Y}^{\text{comm-edge}}$ 包含未来通信边状态, $\mathbf{Y}^{\text{task}}$ 包含任务生命周期、任务完成状态或队列状态。

5.7 双路编码与跨域融合

物理图和通信图先分别编码, 避免一开始把不同语义的变量直接拼接。可以写为:

$$\mathbf{H}_t^{\text{phy}} = f_{\text{phy}} \left(G_{t-H+1:t}^{\text{phy}} \right), \quad \mathbf{H}_t^{\text{comm}} = f_{\text{comm}} \left(G_{t-H+1:t}^{\text{comm}} \right). \quad (13)$$

f_{phy} 可以先用 ST-GCN 或 Temporal Graph Transformer, 重点学习空间邻近和运动趋势; f_{comm} 可以用 GNN + temporal encoder 或 Graph Transformer, 重点学习链路质量和网络性能随时间变化。两路编码后, 再进行跨域融合:

$$\mathbf{H}_t^{\text{fus}} = f_{\text{fus}} \left(\mathbf{H}_t^{\text{phy}}, \mathbf{H}_t^{\text{comm}} \right). \quad (14)$$

融合模块可以先用 Cross-Attention 或 MLP。它的作用是显式建模“运动影响通信, 通信约束反过来影响任务和轨迹”的耦合关系, 而不是简单把两个向量拼在一起。

5.8 动作条件世界模型

如果只做一步或几步预测, 可以写成普通预测模型:

$$\hat{\mathcal{Y}}_t = f_\theta(\mathcal{I}_t). \quad (15)$$

但老师给出的目标包含资源、卸载和轨迹协同, 因此后续更合理的是动作条件世界模型。世界模型维护一个隐状态 $\mathbf{z}_t$, 用来压缩历史信息 and 当前融合表示:

$$\mathbf{z}_t = f_{\text{state}}(\mathbf{z}_{t-1}, \mathbf{a}_{t-1}, \mathbf{H}_t^{\text{fus}}). \quad (16)$$

这个式子表示：当前隐状态不仅由当前观测决定，也由上一时刻隐状态和上一时刻动作决定。这样模型才能回答“如果我刚才选择不同卸载/调度/移动动作，未来会怎样”。

多步 rollout 写为：

$$\hat{\mathbf{z}}_{t+k} = f_{\text{rollout}}(\hat{\mathbf{z}}_{t+k-1}, \mathbf{a}_{t+k-1}), \quad k = 1, \dots, K. \quad (17)$$

rollout 的含义是：在给定未来候选动作序列时，不再依赖真实未来观测，而是在隐空间里一步步推演未来系统状态。RSSM/Dreamer 类世界模型 [4] 的核心思想就是学习隐状态、状态转移和 latent imagination。多智能体世界模型 GAWM[11] 进一步强调全局一致 latent 表示的重要性，这对后续无人机群和多节点协同建模有直接启发。

5.9 训练目标

训练目标需要同时约束物理侧、通信侧和任务侧预测。如果采用 RSSM 或 latent world model，还需要约束先验和后验的一致性。整体损失可以写为：

$$\mathcal{L} = \mathcal{L}_{\text{phy}} + \mathcal{L}_{\text{comm}} + \lambda \mathcal{L}_{\text{task}} + \beta D_{\text{KL}}(q(\mathbf{z}_t | \mathbf{h}_t, \mathbf{x}_t) \| p(\mathbf{z}_t | \mathbf{h}_t)). \quad (18)$$

其中， $\mathcal{L}_{\text{phy}}$ 用于约束位置、速度、覆盖关系等物理侧预测； $\mathcal{L}_{\text{comm}}$ 用于约束速率、链路可用性、CSI/SINR、时延等通信侧预测； $\mathcal{L}_{\text{task}}$ 用于约束任务生命周期、队列或完成状态；KL 项用于约束后验 q 和先验 p 的一致性。训练时后验 q 能看到当前观测，先验 p 只能依赖历史隐状态；让二者接近，是为了提升模型在 rollout 时“闭眼推演”的质量。

6 符号定义表

符号	含义
u_i	第 i 架无人机。
s_m	第 m 个城市事件点或任务点。
b_r	第 r 个边缘节点。
t	当前离散时间步。
H	历史输入窗口长度，即模型观察过去多少步。
K	未来预测步长，即模型预测未来多少步。
$\mathbf{p}_{i,t}$	节点或无人机在时刻 t 的位置。
$\mathbf{v}_{i,t}$	无人机在时刻 t 的速度。
$h_{i,t}$	无人机在时刻 t 的高度。
$b_{i,t}$	无人机在时刻 t 的剩余能量。

$q_{i,t}$	无人机本地队列或待回传数据量。
$c_{i,t}$	无人机本地可用算力。
$D_{m,t}$	事件点在时刻 t 的待采集或待回传数据量。
$C_{m,t}$	事件任务的计算需求。
$\tau_{m,t}$	任务时限或 deadline。
$\rho_{m,t}$	任务优先级或紧急程度。
$d_{ij,t}$	节点 i 和 j 在时刻 t 的空间距离。
$o_{ij,t}$	覆盖或可达指示变量。
$c_{ij,t}$	通信连接指示变量。
$r_{ij,t}$	节点 i 到节点 j 的链路速率。
$\gamma_{ij,t}$	SINR 或 CSI 摘要特征。
$\delta_{ij,t}$	链路传输时延。
$\eta_{ij,t}$	通信资源占用，例如 RB 分配数。
G_t^{phy}	时刻 t 的物理图。
G_t^{comm}	时刻 t 的通信图。
$\mathbf{X}_t$	图中的节点特征矩阵。
$\mathbf{E}_t$	图中的边特征集合。
$\mathbf{a}_t$	时刻 t 的动作或调度决策。
$\mathbf{H}_t^{\text{phy}}$	物理图编码后的时空表示。
$\mathbf{H}_t^{\text{comm}}$	通信图编码后的时空表示。
$\mathbf{H}_t^{\text{fus}}$	物理侧和通信侧融合后的联合表示。
$\mathbf{z}_t$	世界模型维护的联合隐状态。
$q(\cdot)$	后验分布，训练时可利用当前观测修正隐状态。
$p(\cdot)$	先验分布，推演时只依赖历史隐状态进行预测。

7 按周进展

7.1 3.29–3.31：课题理解与世界模型概念

这一阶段完成了两件事。第一，依据 课题介绍.md 和 老师说明.md 明确课题主线：研究对象是物理网络和信息网络的联合预测，落点是无人机通信资源、计算卸载与运动轨迹的协同决策。第二，整理了世界模型的基本逻辑，并在 3.31 汇报中形成“输入数据–图编码器–跨域融合–RSSM 核心–解码头”的五层结构。

当时形成的关键认识是：世界模型不是普通的一步预测器，而是通过隐状态学习系统演化规

律，并支持动作条件下的 what-if 推演。这个认识直接影响了后续公式中的 $\mathbf{z}_t$ 、 $\mathbf{a}_t$ 和 rollout 设计。

7.2 4.7：整体技术链路初步成形

4.7 汇报进一步把课题目标组织成完整方案：双域标准化输入、双路 ST-GCN 编码、双向交叉注意力融合、RSSM 隐状态建模、独立解码输出，以及多场景预训练-微调范式。该阶段的产出是把“物理-信息双域联合预测”从概念落到一个可画出的网络结构。

这一周也明确了后续验证维度：双域预测精度、多步推演稳定性、跨场景泛化能力，以及预测结果对上层联合决策的支撑效果。这个验证思路后来被保留到总体计划中的 baseline、世界模型和迁移阶段。

7.3 4.14：文献调研与方向收敛

4.14 的主要工作是做文献调研，并把文献分成“问题类”和“方法类”。问题类包括移动用户预测性资源分配、RIS-UAV-MEC 联合优化、异构算网协同调度、UAV 通信可移动天线预测控制等；方法类包括 GAWM、TransDreamerV3 等世界模型或多智能体世界模型工作。

这一阶段的结论是：已有问题类论文通常能把资源分配、轨迹、卸载等优化问题建得很细，但它们并不直接解决“如何学习一个可迁移的物理-通信联合状态模型”。已有世界模型论文能提供隐状态和 rollout 思路，但多数不直接面向通信网络状态联合预测。因此，当前课题的合理推进方向是：先把场景状态组织成动态图，再训练联合预测/世界模型，最后再接决策优化。

7.4 4.21：输入、输出、模型与数据来源梳理

4.21 的目标是回应老师“输入、输出、什么网络、什么模型、用什么数据集、链路要讲清楚”的要求。实际产出包括 4.21.md、4.21.pptx 和 4.21_参考文献说明.md。这一周形成了汇报用总链路：

双图输入 → 双路时空编码 → 跨域融合 → 联合隐状态建模 → 多头解码 → 输出/决策接口

这一周还明确了平台和数据资源的定位：

- AirFogSim[10] 作为主仿真平台，用于生成轨迹、链路、任务和资源的联合时间序列。
- GNNNet Challenge 可作为通信网络图建模的公开参照。
- BUPTCMCC-6G-DataAI+[12] 更适合作为无线信道侧先验补充，而不是替代 AirFogSim 的系统级平台。

这个判断避免了把公开数据集和主实验平台混在一起。

7.5 4.27：小场景定义与建模细化

4.27 的重点是把 4.21 的总体链路落到一个具体场景中。最终选定“小规模智慧城市空地协同感知”作为第一版场景：2 架无人机、1 个地面边缘节点、若干城市道路任务点。任务是城市道路突发事件巡查与数据回传。

这一周具体完成了四部分建模。第一，定义了场景实体和任务流程，把抽象网络节点细化成无人机、事件点、边缘节点。第二，重新区分节点状态和边关系，明确节点状态只描述实体自身属性。第三，定义了物理边和通信边：物理边描述距离、覆盖、高度差、相对速度等空间关系；通信边描述链路可用性、速率、时延、回传状态等链路关系。第四，定义了训练样本和预测标签：输入为过去 H 步物理图和通信图序列，标签为未来 K 步节点状态、物理边状态和通信边状态。

这个阶段的核心进展是：从“框架能讲清楚”推进到了“小场景中变量能定义清楚”。

7.6 4.30–5.12: AirFogSim 跑通与数据导出

这一阶段主要完成平台跑通和第一版数据链路构造。AirFogSim/SUMO 小场景已经能够稳定运行，并导出节点、链路和任务三类原始日志：

```
code/AirFogSim/examples/outputs/demo_run_20260507_190930
```

该次仿真为 20 秒、0.1 秒步长，包含车辆、2 架 UAV、4 个 RSU 和 1 个云节点。导出文件包括 `node_states.csv`、`link_states.csv`、`task_states.csv`、`summary.json` 和 `rate.png`，可以覆盖节点状态、通信链路、任务生命周期和资源占用等后续建模所需信息。

在原始日志基础上，进一步构造了第一版可训练数据 `dataset_v0`：

```
code/AirFogSim/examples/outputs/dataset_v0_from_demo_run_20260507_190930
```

当前采用历史窗口 $H = 8$ 、预测步长 $K = 3$ ，共形成 190 条监督学习样本。主要张量包括：

- `x_node`: (190, 8, 37, 7)，对应历史节点状态。
- `x_link`: (190, 8, 188, 5)，对应历史候选链路状态。
- `x_task`: (190, 8, 9)，对应历史任务聚合状态。
- `y_node`、`y_link`、`y_task`，对应未来 $K = 3$ 步预测标签。

配套产物包括字段映射、数据质量报告、样本索引、节点/边词表和可视化结果：

- `field_mapping.md`、`data_quality_report.md`、`sample_index.csv`、`node_vocab.csv`、`edge_vocab.csv`。
- `visuals/` 下的链路速率、双图快照、历史窗口、张量结构和任务生命周期等说明图。
- 5.12 材料目录下的 `5.12.pptx` 及对应讲稿。

本阶段结论是：数据链路已经从“平台能运行”推进到“可训练样本已形成”。当前 `dataset_v0` 可以支撑第一版 baseline，下一步重点是验证链路速率、节点状态和任务状态统计的短期预测效果；严格动作变量仍需后续从调度模块进一步导出。

7.7 5.13–5.15: baseline、随机性、严格动作与动作条件预测

这一阶段的目标是回应老师提出的几个具体问题：AirFogSim 内部是否有状态转移机制、仿真 rollout 的计算量如何、系统中是否存在随机性或扰动、预测结果能否给出置信区间，以及当前方法相对平台默认规则的创新点在哪里。

第一，完成第一版 baseline。 基于 `dataset_v0`，实现了 persistence、Ridge residual 和 MLP residual 三类 baseline。单 seed 测试中，persistence 的整体 RMSE 为 1.345，Ridge residual 的整体 RMSE 为 1.224，MLP residual 的整体 RMSE 为 8.469。该结果说明：短期预测中 persistence 是很强的门槛，因为当前仿真步长为 0.1 秒，预测未来 3 步只对应 0.3 秒；同时也说明简单 MLP 在当前小样本、高维输入下并不稳定。

第二，完成扰动与置信区间评估。 扰动实验在输入侧加入不同强度噪声，观察 clean 训练、noisy 测试下的误差变化。噪声强度从 0.00 增加到 0.30 时，Ridge residual 的整体 RMSE 从 1.224 增加到 7.270，说明当前轻量 baseline 在强扰动下会明显退化。置信区间方面，采用验证集残差分位数法，得到 90% 区间覆盖率 0.902、80% 区间覆盖率 0.849。这说明当前流程已经可以从点预测扩展到不确定性估计，但区间仍然较粗。

第三，完成 AirFogSim 机制和复杂度分析。 AirFogSim 的一步状态转移可以抽象为

$$s_{t+1} = \mathcal{F}_{\text{sim}}(s_t, a_t, \xi_t), \quad (19)$$

其中 s_t 表示节点、链路和任务状态， a_t 表示卸载、RB 分配、CPU 分配和 UAV 移动等调度动作， ξ_t 表示车辆到达、任务生成和信道变化等随机因素。计时实验显示，当前小场景中 AirFogSim 的 `scheduler + env.step` 平均耗时约为 5.9602 ms/step，估算 3-step rollout 约为 17.8807 ms，而 Ridge residual 推理约为 0.004364 ms/sample。这个结果只能说明学习式 world model 存在在线加速空间，不能说明当前 Ridge baseline 可以替代 AirFogSim。

第四，完成多 seed 数据集和跨 seed 泛化测试。 在 seed 0,1,2,3,4 上运行同一场景，构造 `dataset_multiseed_v0`，共 950 条样本，每个 seed 190 条样本。主要张量为

- `x_node`: (950,8,37,7);
- `x_link`: (950,8,188,5);
- `x_task`: (950,8,9);
- `y_node`、`y_link`、`y_task`: 未来 3 步标签。

跨 seed 实验采用 seed 0,1,2 训练，seed 3 验证，seed 4 测试。测试 seed 4 上，persistence 的整体 RMSE 为 1.530，Ridge residual 的整体 RMSE 为 3.303。这个结果说明紧凑线性 residual baseline 跨随机轨迹泛化不足，后续需要更结构化的图模型或世界模型。

第五，完成严格动作日志导出。 此前的 `action_proxy_v0` 是从状态日志反推动作侧变量；本阶段进一步实现 `export_strict_actions_v0.py`，直接在 AirFogSim scheduler 决策时记录动作。记录内容包括任务卸载目标、回传 RSU、RB indices、CPU allocation 和 UAV mobility command。对齐后得到

$$\mathbf{a_hist} : (950, 8, 13), \quad \mathbf{a_future} : (950, 3, 13). \quad (20)$$

这一步使样本从“历史状态到未来标签”推进为“历史状态和动作到未来标签”，为动作条件 world model 做了数据接口准备。

第六，完成动作条件 **baseline**。基于严格动作日志，进一步比较 `state_only_ridge` 和 `state_action_ridge`。测试 seed 4 结果如下：

模型	全部 RMSE	链路 RMSE	任务 RMSE
persistence	1.530	2.280	1.178
state_only_ridge	3.303	6.265	1.209
state_action_ridge	2.990	5.824	0.785

加入严格动作后，Ridge baseline 相比只用状态有提升，尤其任务状态 RMSE 从 1.209 降到 0.785。这说明动作变量确实包含有用的状态转移信息。但它仍未超过 persistence，因此当前结论应保持保守：动作条件建模方向是有信号的，但线性 compact baseline 不够，后续需要双图编码或 latent world model。

本阶段结论。 本阶段已经覆盖老师提出的主要问题：状态转移机制、复杂度、随机性/扰动、置信区间、baseline 和创新点表达。当前创新点不应表述为 AirFogSim 本身，而应表述为：将仿真日志组织成物理图、通信图、任务状态和严格动作共同参与的联合时间序列，并建立从状态预测到动作条件状态推演的实验接口。

8 当前剩余工作

本周任务已经完成，后续工作从“数据链路和动作接口跑通”推进为“结构化模型验证”。下一阶段不宜继续停留在 Ridge baseline，而应围绕动作条件双图模型和世界模型展开。

1. 做扰动训练，而不只是 clean 训练、noisy 测试，检查鲁棒性是否真正改善。
2. 搭建双图编码 baseline，对比普通序列输入、单图输入和物理-通信双图输入。
3. 在严格动作日志基础上搭建动作条件 latent world model，使模型支持多步 rollout。
4. 扩展多场景配置，用于后续预训练和目标场景迁移评估。

9 参考文献

参考文献

- [1] J. Sahili, et al. Spatio-Temporal Prediction using Graph Neural Networks: A Survey. *Neurocomputing*, 625, 2025.
- [2] M. Elgendi, et al. 6G Conditioned Spatiotemporal Graph Neural Networks for Real Time Traffic Flow Prediction. *Scientific Reports*, 16, 2026.
- [3] L. Qin, H. Gu, W. Wei, et al. Spatio-Temporal Communication Network Traffic Prediction Method Based on Graph Neural Network. *Information Sciences*, 679:121003, 2024. DOI: 10.1016/j.ins.2024.121003.

- [4] D. Hafner, T. Lillicrap, I. Fischer, et al. Dream to Control: Learning Behaviors by Latent Imagination. *International Conference on Learning Representations*, 2020. URL: <https://arxiv.org/abs/1912.01603>.
- [5] H. Zhou, W. Xia, G. Zheng, et al. Graph Neural Network-Based Continual Learning for Resource Allocation in Dynamic Wireless Environments. *IEEE Transactions on Vehicular Technology*, 74(12):19125–19140, 2025. DOI: 10.1109/TVT.2025.3585146.
- [6] Z. Tao, W. Xu, Y. Huang, et al. Wireless Network Digital Twin for 6G: Generative AI as a Key Enabler. *IEEE Wireless Communications*, 31(4):24–31, 2024. DOI: 10.1109/MWC.002.2300564.
- [7] X. Huang, H. Yang, C. Zhou, et al. When Digital Twin Meets Generative AI: Intelligent Closed-Loop Network Management. *IEEE Network*, 39(5):272–279, 2025. DOI: 10.1109/MNET.2024.3524474.
- [8] H. Jin, J. Wu, W. Yuan, et al. Co-Design of Sensing, Communications, and Control for Low-Altitude Wireless Networks. *IEEE Transactions on Mobile Computing*, 24:12035–12048, 2025. DOI: 10.1109/TMC.2025.3581616.
- [9] H. Jin, W. Yuan, J. Wu, et al. Advancing the Control of Low-Altitude Wireless Networks: Architecture, Design Principles, and Future Directions. *npj Wireless Technology*, 2:2, 2026. DOI: 10.1038/s44459-025-00010-1.
- [10] Z. Wei, C. Huang, B. Li, Y. Zhao, X. Cheng, L. Yang, and R. Zhang. AirFogSim: A Light-Weight and Modular Simulator for UAV-Integrated Vehicular Fog Computing. arXiv:2409.02518, 2024. URL: <https://arxiv.org/abs/2409.02518>.
- [11] Y. Shi, et al. GAWM: Global-Aware World Model for Multi-Agent Reinforcement Learning. arXiv preprint, 2025.
- [12] P. Yang, Y. Liu, H. Zhang, et al. BUPTCMCC-6G-DataAI+: A Generative Channel Dataset for 6G AI Air-Interface Research. *Science China Information Sciences*, 2025. DOI: 10.1007/s11432-024-4377-y.